BLM4522 – Ağ Tabanlı Paralel Dağıtım Sistemleri
Hasan Kalın - 20291267
GitHub: @hkln4

Drive Video: https://drive.google.com/drive/folders/13OLIp1ahdT-W1hlLpW4e53MtYazaeDaf?usp=sharing

Proje 1: Veri Temizleme ve ETL Süreçleri

1.Giriş

Bu proje kapsamında messy_HR_data.csv (GitHub'a yüklendi) üzerinde PostgreSQL ve DBeaver kullanılarak tam bir ETL süreci uygulandı. Veriler; eksik değerler, metin olarak girilmiş sayılar ve tutarsız tarih formatları gibi çok sayıda kalite sorunu içermekteydi.

2. Extract: Staging Tablosu Oluşturma ve Hedef Tablo Oluşturma

```sql
DROP TABLE staging_hr;

CREATE TABLE staging_hr (
    "Name" TEXT,
    "Age" TEXT,
    "Salary" TEXT,
    "Gender" TEXT,
    "Department" TEXT,
    "Position" TEXT,
    "Joining Date" TEXT,
    "Performance Score" TEXT,
    "Email" TEXT,
    "Phone Number" TEXT
);

SELECT * FROM staging_hr LIMIT 10;

-- total kayıt
SELECT COUNT(*) FROM staging_hr;

-- Age'deki kirli veriler
SELECT DISTINCT "Age" FROM staging_hr;

-- Salary'daki kirli veriler
SELECT DISTINCT "Salary" FROM staging_hr;

-- Joining Date formatları
SELECT DISTINCT "Joining Date" FROM staging_hr;

-- Boş email'ler
SELECT COUNT(*) FROM staging_hr WHERE "Email" IS NULL OR TRIM("Email") = '' OR "Email" = 'nan';
```

Ham veriyi olduğu gibi saklamak için tüm sütunlar TEXT tipinde tanımlandı. Veri setindeki; eksik verileri, farklı formatları anlamak için keşifsel veri analizi yapıldı.

Toplam kayıt	Age'deki veriler	Salary'deki veriler	Joining Date formatları	Boş Emailler
1000	40	55000	03-25-2019	390
	35	Nan	01/15/2020	
	Nan	70000	2020/02/20	
	thirty	SIXTY THOUSAND	2019.12.01	
	50	50000	April 5, 2018	
	25	65000		

```sql
CREATE TABLE clean_hr (
    id SERIAL PRIMARY KEY,
    name VARCHAR(100),
    age INTEGER,
    salary NUMERIC(10,2),
    gender VARCHAR(20),
    department VARCHAR(50),
    position VARCHAR(50),
    joining_date DATE,
    performance_score VARCHAR(5),
    email TEXT,
    phone_number VARCHAR(20),
    loaded_at TIMESTAMP DEFAULT NOW()
);
```

Görüldüğü üzere Age, Salary ve Joining Date sütunlarında farklı formatta veriler bulunuyor. Transform adımında gerekli işlemlerle bu veriler standartlaştırılacaktır.

Load adımında temizlenmiş veriyi yükleyeceğimiz clean_hr tablosu uygun veri tipleriyle oluşturuldu.

3. Transform + Load

```sql
INSERT INTO clean_hr (
    name, age, salary, gender, department, position,
    joining_date, performance_score, email, phone_number
)
SELECT
    -- Name: baştaki/sondaki boşlukları temizle
    TRIM("Name"),

    -- Age: 'nan' ve 'thirty' gibi metin değerleri NULL yap, geçerli sayıları integer'a çevir
    CASE
        WHEN TRIM("Age") ~ '^\d+$' THEN TRIM("Age")::INTEGER
        ELSE NULL
    END,

    -- Salary: 'NAN' → NULL, 'SIXTY THOUSAND' → 60000
    CASE
        WHEN TRIM("Salary") = 'NAN' THEN NULL
        WHEN TRIM("Salary") = 'SIXTY THOUSAND' THEN 60000
        WHEN TRIM("Salary") ~ '^\d+$' THEN TRIM("Salary")::NUMERIC
        ELSE NULL
    END,

    -- Gender: olduğu gibi
    TRIM("Gender"),
    -- Department
    TRIM("Department"),
    -- Position
    TRIM("Position"),

    -- Joining Date: 5 farklı formatı standart DATE'e çevir
    CASE
        WHEN "Joining Date" ~ '^\d{4}/\d{2}/\d{2}$'
            THEN TO_DATE("Joining Date", 'YYYY/MM/DD')
        WHEN "Joining Date" ~ '^\d{2}/\d{2}/\d{4}$'
            THEN TO_DATE("Joining Date", 'MM/DD/YYYY')
        WHEN "Joining Date" ~ '^\d{4}\.\d{2}\.\d{2}$'
            THEN TO_DATE("Joining Date", 'YYYY.MM.DD')
        WHEN "Joining Date" ~ '^\d{2}-\d{2}-\d{4}$'
            THEN TO_DATE("Joining Date", 'MM-DD-YYYY')
        WHEN "Joining Date" ~ '^[A-Za-z]+ \d+, \d{4}$'
            THEN TO_DATE("Joining Date", 'Month DD, YYYY')
        ELSE NULL
    END,
    -- Performance Score
    TRIM("Performance Score"),
```

Name sütununa TRIM("Name") uygulayarak baştaki ve sondaki boşlukları temizlendi.

Age sütununda TRIM("Age") ~ '^\d+$' ile rakamlardan oluşan değerler kontrol edildi. Geçerliyse INT'e çevirildi.Ayrıca thirty manuel olarak 30'a çevrildi. Geriye kalanlar NULL yapıldı.

Salary sütunuda, SIXTY THO.. 60000 sayısına çevrildi, sadece rakamlardan oluşuyorsa NUMERIC tipine dönüştürüldü. Hiçbiri değilse NULL.

Joining Date sütununda, Regex ile her satırın hangi formatta olduğu tespit edilerek, TO_DATE() ile standart bir formata dönüşüm yapıldı.

Email / Phone sütunuda, TRIM() sonrası geçerli değerler TRIM'lendi. Geriye kalanlar ise NULL yapıldı.

Gender / Department / Position / Performance Score sütunlarına Sadece TRIM() uygulandı.

Ayrıca dönüştürülen tüm veriler temiz clean_hr tablosuna yüklendi.

4. Veri Kalitesi Raporu

```sql
-- 1. Genel kayıt sayısı
SELECT COUNT(*) AS toplam_kayit FROM clean_hr;

-- 2. NULL değer sayıları (her sütun için)
SELECT
    COUNT(*) - COUNT(name) AS bos_name,
    COUNT(*) - COUNT(age) AS bos_age,
    COUNT(*) - COUNT(salary) AS bos_salary,
    COUNT(*) - COUNT(email) AS bos_email,
    COUNT(*) - COUNT(phone_number) AS bos_phone,
    COUNT(*) - COUNT(joining_date) AS bos_joining_date
FROM clean_hr;

-- 3. Yaş dağılımı
SELECT MIN(age), MAX(age), ROUND(AVG(age),1) AS ort_yas
FROM clean_hr;

-- 4. Maaş dağılımı
SELECT MIN(salary), MAX(salary), ROUND(AVG(salary),2) AS ort_maas
FROM clean_hr WHERE salary IS NOT NULL;

-- 5. Departmana göre çalışan sayısı
SELECT department, COUNT(*) AS calisan_sayisi
FROM clean_hr
GROUP BY department
ORDER BY calisan_sayisi DESC;

-- 6. Performance score dağılımı
SELECT performance_score, COUNT(*) AS adet
FROM clean_hr
GROUP BY performance_score
ORDER BY performance_score;

-- 7. Joining date yıllara göre dağılım
SELECT EXTRACT(YEAR FROM joining_date) AS yil, COUNT(*) AS adet
FROM clean_hr
WHERE joining_date IS NOT NULL
GROUP BY yil
ORDER BY yil;
```

Transform sonrası clean_hr üzerinde aşağıdaki analiz sorguları çalıştırıldı.

Sonuçlar aşağıdaki gibidir:

Analiz	Sonuç
Toplam kayıt	1000
Boş Name,Age, Salary, Email, Phone, Joining Date	0, 335, 167, 390, 376, 0
Yaş dağılımı	Min: 25 | Max: 50 | Ort: 37.3
Maaş dağılımı	Min: 50000 | Max: 70000 | Ort: 60216.09
Departmana göre çalışan sayısı	Finance: 218 | Sales: 202 | HR: 200 | IT: 193 | Marketing: 187
Performans skoruna göre dağılım	A: 192 | B: 225 | C: 192 | D: 190 | F: 201
Joining Date ve yıllara göre dağılım	2018: 186 | 2019: 385 | 2020: 429

5. Sonuç

Bu projede 1000 satırlık messy_HR_data.csv dosyası üzerinde PostgreSQL ve DBeaver kullanılarak eksiksiz bir ETL süreci uygulandı.

Extract aşamasında ham veri, tüm sütunları TEXT tipinde tanımlanmış staging_hr tablosuna aktarıldı. Bu sayede veri hiçbir dönüşüme uğramadan saklandı ve ön analiz sorguları ile kalite sorunları tespit edildi: Age ve Salary sütunlarında metin olarak girilmiş sayısal değerler, Joining Date sütununda 5 farklı tarih formatı ve 390'dan fazla kayıtta geçersiz e-posta verisi.

Transform aşamasında tespit edilen sorunlar SQL CASE ifadeleri ve regex desenleriyle çözüldü. Metin olarak girilmiş sayılar (thirty → 30, SIXTY THOUSAND → 60000) dönüştürüldü, anlamsız değerler (nan, NAN) NULL'a çevrildi, 5 farklı tarih formatı TO_DATE() fonksiyonu ile standart DATE tipine getirildi ve tüm metin alanlarında TRIM() uygulandı.

Load aşamasında dönüştürülen 1000 satır, doğru veri tipleriyle tanımlanmış clean_hr tablosuna tek bir INSERT INTO ... SELECT sorgusuyla yüklendi.

Son olarak veri kalitesi raporu sorguları ile yüklenen verinin doğruluğu doğrulandı; yaş, maaş ve departman bazlı dağılımlar analiz edildi.